

# Échantillonnage Préférentiel

## *Options exotiques*

Louis Douge & Nidham Gazagnadou

ENSTA ParisTech

28 Avril 2016



# Plan de la présentation

- 1 Théorie du projet
  - Le modèle
  - Échantillonnage préférentiel
  - Optimisation
- 2 Implémentation des estimations
  - Modèle unidimensionnel sur call européen
  - Modèle tridimensionnel sur call sur panier
  - Modèle tridimensionnel sur call altiplano
- 3 Méthode de réduction de variance

## Le modèle de Black-Scholes

Vecteur des prix des actifs risqués  $S(t) = (S_1(t), S_2(t), S_3(t))$

Mouvement brownien  $W(t) = (W_1(t), W_2(t), W_3(t))$  de matrice de corrélation :

$$\begin{pmatrix} 1 & \rho_{1,2} & \rho_{1,3} \\ \rho_{1,2} & 1 & \rho_{2,3} \\ \rho_{1,3} & \rho_{2,3} & 1 \end{pmatrix}$$

La dynamique des cours est donnée par :

$$\frac{dS_i(t)}{S_i(t)} = rdt + \sigma_i dW_i(t), \forall i \in \{1, 2, 3\}$$

# Détermination du prix $S(t)$

Pour  $i \in \{1,2,3\}$ ,  $S_i$  est un processus d'Itô, on applique donc la formule d'Itô au processus suivant :

$$\begin{aligned}\log(S_i(t)) &= \log(S_i(0)) + \int_0^t \frac{dS_i u}{S_i(u)} + \frac{1}{2} \int_0^t \frac{\sigma_i^2 S_i(u)^2 du}{-S_i(u)^2} \\ &= \log(S_i(0)) + \int_0^t r du + \int_0^t \sigma_i dW_i u - \frac{1}{2} \sigma_i^2 t \\ &= \log(S_i(0)) + (r - \frac{\sigma_i^2}{2})t + \sigma_i W_i(t)\end{aligned}$$

En conclusion,

$$S_i(t) = S(0) \exp((r - \frac{\sigma_i^2}{2})t + \sigma_i W_i(t)), \forall i \in \{1, 2, 3\}$$

# Égalité des espérances

Pour  $g : \mathbb{R}^n \rightarrow \mathbb{R}$ , intégrable

$$\forall \theta \in \mathbb{R}_n, \mathbb{E}[g(X)] = \mathbb{E}[g(X + \theta)e^{-\theta \cdot X - \frac{1}{2}|\theta|^2}]$$

Intervalle de confiance (de niveau 90%) :

$$\left[ \mathbb{E}[g(X)] \pm 1,6449 \sqrt{\frac{\text{Var}(g(X))}{N}} \right]$$

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}^n} g(x) \frac{e^{\frac{-x^t \Sigma^{-1} x}{2}}}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} dx \text{ (par définition)}$$

# Égalité des espérances

$$\begin{aligned}\mathbb{E}[g(X)] &= \int_{\mathbb{R}^n} g(x) \frac{e^{\frac{-x^t \Sigma^{-1} x}{2}}}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} dx \text{ (par définition)} \\ &= \int_{\mathbb{R}^n} g(x) \frac{e^{\frac{-x^t x}{2}}}{(2\pi)^{\frac{n}{2}}} dx \text{ (car ici } \Sigma = I_n) \\ &= \int_{\mathbb{R}^n} g(x + \theta) \frac{e^{\frac{-x^t x}{2}}}{(2\pi)^{\frac{n}{2}}} e^{-\theta^t x - \frac{1}{2}|\theta|^2} dx\end{aligned}$$

avec le changement de variable  $x := x + \theta$ , et après simplification.  
On a bien finalement :

$$\forall \theta \in \mathbb{R}^n \mathbb{E}[g(X)] = \mathbb{E}[\underbrace{g(X + \theta) e^{-\theta^t X - \frac{1}{2}|\theta|^2}}_{f(\theta, X)}]$$

# Quel $\theta$ choisir ?

Il s'agit d'annuler le gradient de la variance

$$\nabla_{\theta} \text{Var}(f(\theta, X)) = \mathbb{E}[(\theta - X)g(X)^2 e^{-\theta X + \frac{1}{2}|\theta|^2}]$$

$$\nabla_{\theta} \text{Var}(f(\theta, X)) = \nabla_{\theta} \mathbb{E}[f^2(\theta, X)]$$

- Retour à la définition :  $\nabla_{\theta} \int_{\mathbb{R}^n} g^2(x + \theta) e^{-2\theta x - |\theta|^2} \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx$
- changement de variable  $y := x + \theta$
- Théorème de dérivation sous l'intégrale  $\nabla_{\theta} \int_{\mathbb{R}^n} = \int_{\mathbb{R}^n} \nabla_{\theta}$

# Prix analytique dans le cas d'un call européen

## Modèle unidimensionnel de call européen

$$g : x \in \mathbb{R} \rightarrow (S_0 \cdot e^{(r - \frac{\sigma^2}{2})t + \sigma W(t)} - K)_+ = (S_T - K)_+$$

$$\begin{aligned} P &= e^{-rT} \mathbb{E}[g(X)] \\ &= \dots \\ &= S_0 \phi(d_1) - K e^{-rT} \phi(d_2) \end{aligned}$$

Avec  $\phi$  la fonction de répartition d'une loi normale et  $d_1$  et  $d_2$

$$\text{définis par : } \begin{cases} d_2 &:= \frac{1}{\sigma\sqrt{T}} [\log \frac{S_0}{K} + (r - \frac{\sigma^2}{2}) T] \\ d_1 &:= \sigma\sqrt{T} + d_2 \end{cases}$$



# Estimation de $\theta_{\star}^N$ , limite de $(\theta_n^N)_{n \in \mathbb{N}}$

## Algorithme de Newton

$$\forall n \in \mathbb{N} \begin{cases} \theta_0^N & = 0 \\ u_N(\theta_n^N) + \nabla u_N(\theta_n^N) \cdot (\theta_{n+1}^N - \theta_n^N) & = 0 \end{cases}$$

Dans notre cas on a :

$$u_N(\theta) = \frac{1}{N} \sum_{i=1}^N (\theta - X_i) g(X_i)^2 e^{-\theta \cdot X_i + \frac{1}{2} |\theta|^2}$$

On calcule également le gradient  $\nabla_{\theta} A$  :

$$\nabla u_N(\theta) = \frac{1}{N} \sum_{i=1}^N g(X_i)^2 \nabla_{\theta} \underbrace{[(\theta - X_i) e^{-\theta \cdot X_i + \frac{1}{2} |\theta|^2}]}_A$$

Estimation de  $\theta_{\star}^N$ , limite de  $(\theta_n^N)_{n \in \mathbb{N}}$ 

On calcule également le gradient  $\nabla_{\theta} A$  :

$$\nabla u_N(\theta) = \frac{1}{N} \sum_{i=1}^N g(X_i)^2 \nabla_{\theta} \underbrace{[(\theta - X_i) e^{-\theta \cdot X_i + \frac{1}{2} |\theta|^2}]}_A$$

Le calcul de  $\nabla_{\theta} A = (\frac{\partial A_i}{\partial \theta_j})_{1 \leq i, j \leq 3}$  donne alors :

$$\begin{pmatrix} 1 + (\theta_1 - X_i^{(1)})^2 & (\theta_1 - X_i^{(1)})(\theta_2 - X_i^{(2)}) & (\theta_1 - X_i^{(1)})(\theta_3 - X_i^{(3)}) \\ (\theta_2 - X_i^{(2)})(\theta_1 - X_i^{(1)}) & 1 + (\theta_2 - X_i^{(2)})^2 & (\theta_2 - X_i^{(2)})(\theta_3 - X_i^{(3)}) \\ (\theta_3 - X_i^{(3)})(\theta_1 - X_i^{(1)}) & (\theta_3 - X_i^{(3)})(\theta_2 - X_i^{(2)}) & 1 + (\theta_3 - X_i^{(3)})^2 \end{pmatrix}$$

Où l'on adopte les notations suivantes :

$X_i = (X_i^{(1)}, X_i^{(2)}, X_i^{(3)})$  avec  $1 \leq i \leq N$ ,  $N$  nombre de simulation.

## Premiers résultats numériques


Paramètres :  $\sigma = 0.3$ ;  $S_{1,0} = 1$ ;  $r = 0.01$ ;  $T = 2$ ;  $K = 1$

Pour  $N = 10^6$

$$P_{analytique} = P_{simu} = 0.176006$$

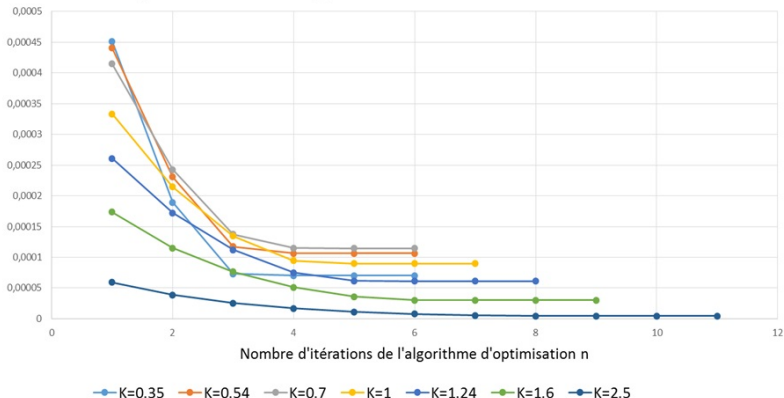
$$\sqrt{\frac{\text{Var}(f(\theta_*, X))}{N}} = 3.12209 \times 10^{-4}$$

# Choix du nombre d'itérations de Monte-Carlo




# Réduction de la variance grâce à $\theta^*$

Suite de  $\left( \sqrt{\frac{1}{N} \text{Var}(f(\theta_n^N, X))} \right)_n$  en fonction de n (nombre d'itérations de l'algorithme de Newton) pour différentes valeurs de strike K



# Comparaison de $P(\theta = 0)$ et $P(\theta = \theta^*)$ - $K=2,5$



# Prix d'un call sur panier

## Call sur panier

$$h(x_1, x_2, x_3) = (\lambda_1 x_1 + \lambda_2 x_2 + \lambda_3 x_3 - K)_+$$

La fonction  $g$  à appliquer aux échantillons  $X = (X_1, X_2, X_3)$  suivants une  $N(0, I_3)$  est la suivante :

$h(S(\phi(X)))$  avec :

- $\phi$  génère les browniens arrêtés en  $T$  par la matrice  $A$ , racine carrée de  $\Gamma$  (Cholesky) :  $W_T \sim \sqrt{T}AG$  où  $G \sim N(0, I_3)$  et  $AA^* = \Gamma$ .
- $S$  est le vecteur de prix arrêté au temps  $T$ , fonction du brownien généré par  $\phi$
- $h$  est la fonction call sur panier.

## Prix d'un call sur panier (Conditions de la question 12)




Figure: Prix du call sur panier sans échantillonnage préférentiel



# Prix d'un call sur panier (Conditions de la question 12)




Figure: Prix du call sur panier avec échantillonnage préférentiel

Pour  $N=1e6$ ,  $\theta^* = (1.4628, 0.910423, 0.691786)$

# Amplitude de l'intervalle de confiance d'un call sur panier (Conditions de la question 12)

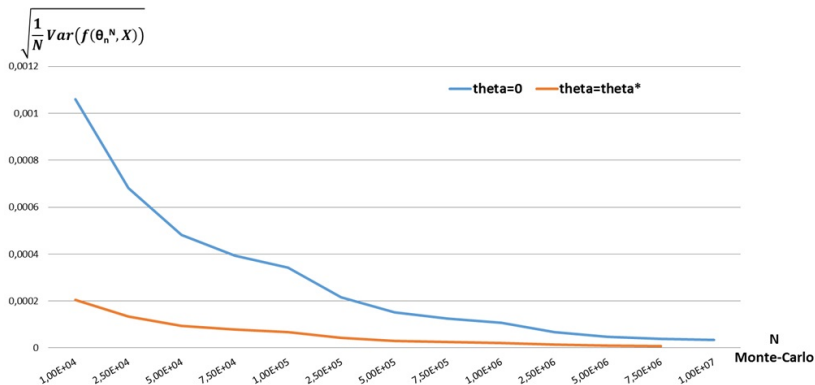


Figure: Amplitude de l'intervalle de confiance en fonction de N de Monte-Carlo

## Prix call altiplano

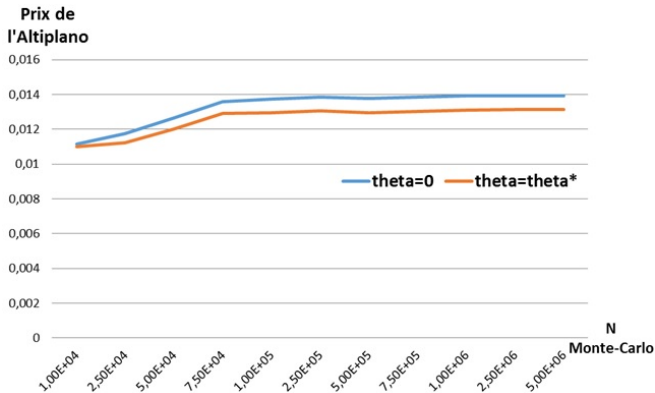


Figure: Prix du call altiplano avec et sans échantillonnage préférentiel

# Amplitude de l'intervalle de confiance - Altiplano

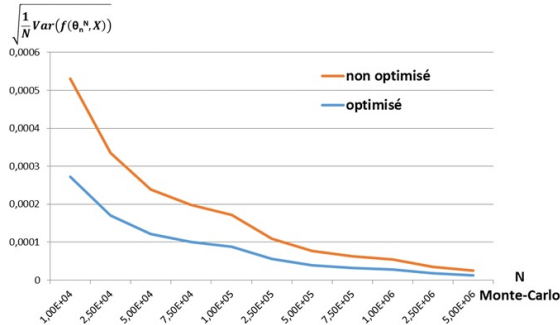


Figure: Amplitude de l'intervalle de confiance en fonction de N de Monte-Carlo

Pour  $N=1e6$ ,  $\theta^* = (0.171176, 0.11596, 0.0991768)$ .

## Réduction de variance par variables de contrôle

On pose

$$\begin{cases} X &= (\lambda_1 S_1(T) + \lambda_2 S_2(T) + \lambda_3 S_3(T) - K)_+ \\ Y &= X - (K - \lambda_1 S_1(T) - \lambda_2 S_2(T) - \lambda_3 S_3(T))_+ \end{cases}$$

On remarque que  $\mathbb{E}[Y] = e^{rT} - K$  (en se plaçant sous la probabilité risque neutre où  $\tilde{S}_t$  est une martingale). Alors :

$$\mathbb{E}[X - Y] + e^{rT} - K = \mathbb{E}[X]$$

On calculera donc l'intervalle de confiance en se basant sur  $\mathbb{V}ar(X - Y)$  et non plus  $\mathbb{V}ar(X)$  si :

$$\mathbb{V}ar(X - Y) \ll \mathbb{V}ar(X)$$

Application numérique (estimateur empirique) :

$$\mathbb{V}ar(X - Y) = 0.0312655 \text{ et } \mathbb{V}ar(X) = 0.068763.$$

# Conclusion

- Quelques incohérences à corriger, malgré des ordres de grandeurs qui semblent satisfaisants
- Complexité du code : nécessité d'exploiter les possibilités de la programmation objet (redondance des mêmes structures).